2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 37

Viramontes alejo,jeansen radhames

laugier,gonzalo

tomas,rocha

1. Introducción

El presente trabajo práctico tiene como objetivo realizar un análisis exploratorio y estadístico de un conjunto de datos relacionado con la economía de combustible y las características técnicas de vehículos correspondientes al año modelo 2025. La información utilizada proviene de la Environmental Protection Agency (EPA) de Estados Unidos, organismo que realiza y recopila ensayos destinados a determinar las estimaciones de eficiencia energética de los vehículos.

El conjunto de datos contiene información de distintas configuraciones de vehículos sometidas a prueba e incluye variables relacionadas con el fabricante, modelo, características del motor, potencia, cilindrada, transmisión, sistema de tracción, tipo de combustible y resultados de economía de combustible y emisiones. Estos atributos permiten estudiar cómo determinadas características técnicas pueden relacionarse con el rendimiento de los vehículos.

Uno de los principales aspectos considerados en el trabajo es la economía de combustible, expresada en millas por galón (MPG). Esta medida representa la distancia que puede recorrer un vehículo utilizando una determinada cantidad de combustible, por lo que un valor más elevado indica una mayor eficiencia. Su comportamiento puede estar relacionado con diversos factores, como el peso, la potencia, el tipo de motor, la transmisión y el sistema de tracción.

A partir de esta información, se realiza una exploración inicial de los datos para conocer su estructura, identificar patrones, analizar la distribución de las variables y detectar posibles valores nulos, registros duplicados o valores atípicos. Posteriormente, se lleva a cabo un proceso de limpieza y preparación, justificando las modificaciones realizadas para obtener un conjunto de datos adecuado para los análisis posteriores.

Finalmente, se plantean y evalúan diferentes hipótesis con el propósito de estudiar las relaciones entre las variables y obtener conclusiones a partir de los resultados. Para ello, se utilizan herramientas estadísticas y gráficas que permiten analizar los datos desde distintas perspectivas, tanto de manera individual como considerando la relación entre dos o más características.

De esta manera, el trabajo busca aplicar los conceptos y herramientas de la Ciencia de Datos para transformar un conjunto de datos en información útil, identificar relaciones entre las características técnicas de los vehículos y su economía de combustible, y evaluar qué factores pueden estar asociados con una mayor eficiencia energética.

1. Análisis exploratorio de los datos

En esta primera etapa realizamos un análisis exploratorio sobre el dataset para comprender su estructura, detectar datos faltantes y revisar posibles valores atípicos. Evaluamos los tipos de variables, las distribuciones categóricas y las estadísticas descriptivas de los datos numéricos para asegurar la consistencia de la información antes de avanzar

1.1. Estructura y características generales

En primer lugar, se verificaron las dimensiones del conjunto mediante df.shape y se inspeccionaron los primeros registros con df.head(), tal como se muestra en la Sección 1.2 de la notebook. Se obtuvo una base de 4.287 filas y 67 columnas.

Las variables pueden agruparse, de manera general, en información de identificación del vehículo, características del motor, transmisión y sistema de tracción, combustible utilizado, condiciones de ensayo y resultados de economía de combustible y emisiones. Esta diversidad permite estudiar diferentes aspectos del problema, aunque también requiere interpretar cada variable de acuerdo con su significado.

En la Sección 1.4 analizamos los tipos de datos con df.info() y armamos una tabla resumen con nulos, porcentajes de datos faltantes y valores únicos por columna. Esto nos permitió detectar variables guardadas como números que en realidad representan códigos categóricos.

1.1.1. Caracterización de las variables

Para encarar el análisis exploratorio, clasificamos las variables del dataset según su tipo y escala de medición en cuantitativas (continuas y discretas) y cualitativas (nominales y ordinales).

Variables cuantitativas continuas

Son aquellas que pueden tomar valores numéricos con decimales dentro de un intervalo, según la precisión de la medición.

- **Test Veh Displacement (L):** representa la cilindrada del vehículo, expresada en litros.
- **Axle Ratio:** indica la relación de transmisión del eje.
- **N/V Ratio:** representa la relación entre la velocidad del motor y la velocidad del vehículo.
- **RND_ADJ_FE:** representa la economía de combustible ajustada, expresada en MPG.
- **Target Coef A, Target Coef B y Target Coef C:** corresponden a los coeficientes objetivo del modelo de resistencia al avance.

- **Set Coef A, Set Coef B y Set Coef C:** representan los coeficientes establecidos para las condiciones de prueba.
- **CO2, CO, NOx, THC, CH4, PM y N2O:** representan las emisiones de gases y partículas, expresadas en gramos por milla (g/mi).
- **Rated Horsepower:** representa la potencia nominal del vehículo. El conjunto de datos se registra mediante valores enteros.

Variables cuantitativas discretas

Son aquellas que toman valores numéricos separados, generalmente enteros, y permiten contar elementos o representar cantidades registradas en unidades específicas.

- **Model Year:** indica el año del modelo del vehículo. En este conjunto de datos, todos los registros corresponden a 2025, por lo que la variable es constante y no aporta variabilidad al análisis.
- **# of Cylinders and Rotors:** indica la cantidad de cilindros y rotores del motor.
- **# of Gears:** representa la cantidad de marchas de la transmisión.
- **Equivalent Test Weight (lbs.):** indica el peso equivalente del vehículo utilizado durante las pruebas, registrado en libras.

Variables cualitativas nominales

Son aquellas que representan categorías o nombres sin un orden jerárquico natural entre sus valores.

- **Vehicle Manufacturer Name:** identifica al fabricante del vehículo.
- **Represented Test Veh Make:** indica la marca representada en la prueba.
- **Vehicle Type:** describe el tipo de vehículo.
- **Tested Transmission Type:** identifica el tipo de transmisión evaluada.
- **Drive System Description:** describe el sistema de tracción del vehículo.
- **Test Fuel Type Description:** identifica el tipo de combustible o fuente de energía utilizada.
- **Test Category:** indica la categoría de la prueba, como FTP, HWY, CD, US06 o SC03.
- **Test Procedure Description:** describe el procedimiento de prueba aplicado.
- **Transmission Overdrive Code:** contiene un código relacionado con la sobremarcha de la transmisión.
- **Shift Indicator Light Use Cd:** identifica mediante un código el uso de la luz indicadora de cambio de marcha.
- **Test Procedure Cd:** contiene el código correspondiente al procedimiento de prueba.
- **Test Fuel Type Cd:** identifica mediante un código el tipo de combustible utilizado.
- **Test Veh Configuration #:** identifica una configuración del vehículo. Aunque contiene números, funciona como un identificador y no como una medida cuantitativa. Para distinguir las configuraciones se consideran conjuntamente los campos Veh Mfr Code, Test Vehicle ID y Test Veh Configuration #.

Variables cualitativas ordinales

Son aquellas que representan categorías que pueden ordenarse de acuerdo con un criterio determinado, como un nivel de intensidad, una clasificación o una escala de valoración. En la lista de variables analizadas no se identifican variables ordinales de manera directa. Las categorías de las pruebas, los tipos de transmisión y los tipos de combustible no presentan un orden jerárquico natural, por lo que se clasifican como nominales.

Consideraciones para el análisis

Esta clasificación nos sirvió para aplicar el tratamiento adecuado a cada variable (métricas descriptivas en continuas y tablas de frecuencia en discretas y categóricas).

Durante la revisión, detectamos valores fuera de rango como 99.999 en Test Veh Displacement (L), 999 en N/V Ratio y 10000 en RND_ADJ_FE. Todo indica que corresponden a códigos de error o marcadores especiales del dataset, por lo que analizaremos su significado antes de decidir si los eliminamos o imputamos.

1.2. Análisis de los valores faltantes

Al revisar los valores nulos (Secciones 1.3 y 1.4), vimos que los datos faltantes no se reparten de forma pareja en todo el dataset, sino que se concentran en unas pocas columnas específicas.

Atributo	**Cantidad de valores nulos**	**Porcentaje de nulos**
Averaging Group ID	4.212	98,25 %
Averaging Weighting Factor	4.212	98,25 %
ADFE Test Number	4.075	95,05 %
ADFE Total Road Load HP	4.075	95,05 %
ADFE N/V Ratio	4.075	95,05 %
ADFE Equiv. Test Weight (lbs.)	4.075	95,05 %
FE Bag 4	3.899	90,95 %
PM (g/mi)	3.898	90,93 %
FE Bag 3	2.834	66,11 %
RND_ADJ_FE	221	5,16 %

Tabla 1. Atributos seleccionados con mayor proporción de valores faltantes. Los resultados se obtuvieron mediante el análisis de valores nulos de las secciones 1.3 y 1.4 de la notebook.

Varias columnas superan el 95% de nulos, mientras que en otras el faltante es muy bajo, como en RND_ADJ_FE con un 5,16% (221 registros). Que una columna tenga nulos no implica borrar automáticamente, ya que muchas variables corresponden a ensayos específicos o aplican solo a ciertos tipos de motor. Por eso, evaluaremos la relevancia de cada atributo antes de decidir si filtramos filas, imputamos o descartamos la variable.

1.3. Distribución de las categorías de prueba

En la Sección 1.5 analizamos la variable *Test Category* para ver cómo se reparten los registros entre los diferentes tipos de ensayo.

Categoria de prueba	**Cantidad de registros**	**Porcentaje**
FTP	1.577	36,8 %
HWY	1.340	31,3 %
CD	695	16,2 %
US06	412	9,6 %
SC03	263	6,1 %
Total	**4.287**	**100 %**

Tabla 2. Cantidad y porcentaje de registros por categoría de prueba. Elaboración propia a partir del análisis realizado en la Sección 1.5 de la notebook.

Las categorías FTP y HWY representan casi el 68% de los registros, mientras que el resto se divide en otros ciclos de prueba menos frecuentes. Dado que el dataset mezcla pruebas urbanas y de ruta, no podemos usar todos los datos juntos si queremos evaluar una hipótesis de consumo estrictamente urbano.

1.4. Distribución de los tipos de combustible

También se analizaron las frecuencias de *Test Fuel Type Description*, con el propósito de conocer la composición del conjunto según el tipo de combustible utilizado en los ensayos.

Tipo de combustible de prueba	**Cantidad de registros**	**Porcentaje**
Tier 2 Cert Gasoline	3.236	75,5 %
Electricity	654	15,3 %
Cold CO Regular (Tier 2)	160	3,7 %
Federal Cert Diesel 7-15 PPM Sulfur	150	3,5 %

Cold CO Premium (Tier 2)	57	1,3 %
Otras categorias	30	0,7 %
Total	**4.287**	**100 %**

Tabla 3. Distribución de los registros según el tipo de combustible de prueba. Las categorías restantes incluyen combustibles y mezclas con menor representación. Código: Sección 1.5.

El 75,5% de las pruebas corresponden a vehículos a nafta/gasolina y un 15,3% a eléctricos. Como el dataset mezcla distintas tecnologías de propulsión, no todas las variables se aplican de la misma forma. Esto es fundamental para las hipótesis sobre motores de combustión, donde tendremos que filtrar el dataset y aislar este grupo para evitar sesgar el análisis.

En cuanto a fabricantes, los tres con mayor presencia son GM (697 registros), BMW (597) y Toyota (523). Vale aclarar que estas cifras indican volumen de pruebas y no la cantidad de modelos comerciales distintos (Sección 1.5).

1.5. Configuraciones únicas y registros repetidos

En la Sección 1.6 combinamos las columnas Veh Mfr Code, Test Vehicle ID y Test Veh Configuration # para identificar las configuraciones únicas del dataset. Además, chequeamos si existían filas exactamente duplicadas en la base.

Indicador	**Cantidad**
Registros totales	4.287
Configuraciones únicas	1.448
Registros adicionales asociados a configuraciones ya observadas	2.839
Filas duplicadas exactas	0

Tabla 4. Resumen del análisis de configuraciones únicas y duplicados exactos. Código: Sección 1.6 de la notebook.

Identificamos 1.448 configuraciones únicas sobre el total de 4.287 registros y confirmamos que no existen duplicados exactos en la base.

Que una configuración aparezca varias veces es esperable, ya que un mismo vehículo suele evaluarse bajo diferentes categorías o condiciones de prueba. Por eso no consideramos estas repeticiones como un error ni corresponde borrarlas, sino que mantendremos los registros según el filtro que requiera cada análisis.

1.6. Estadísticas descriptivas de las variables numéricas

En la Sección 1.7 calculamos las estadísticas descriptivas (media, desvío estándar, cuartiles y rangos) para las variables técnicas y los resultados de las pruebas.

A continuación, se resumen los valores más relevantes:

Variable	Valores no nulos	Mediana	Maximo
Test Veh Displacement (L)	4.287	2,487	99,999
Rated Horsepower	4.287	305	1.948
# of Cylinders and Rotors	3.617	4	16
# of Gears	4.287	1	10
Equivalent Test Weoght (lbs.)	4.287	4.750	9.000
Axle Ratio	4.287	3,45	9.99
N/V Ratio	4.287	25,7	999
RND_ADJ_FE	4.066	32,9	10.000

Tabla 5. Estadísticas descriptivas seleccionadas de variables técnicas y resultados de ensayo. Código: Sección 1.7 de la notebook.

Al comparar medianas y máximos se notan saltos muy marcados. Por ejemplo, la cilindrada pasa de una mediana de 2,487 L a un máximo de 99,999 L, mientras que en N/V Ratio y RND_ADJ_FE figuran máximos de 999 y 10.000.

En RND_ADJ_FE, la dispersión es clara: con una media de 64,96 y una mediana de 32,9, el desvío estándar se dispara a 456,94. Esta distorsión confirma el peso que tienen los datos atípicos en el promedio, lo que nos obliga a usar gráficos de distribución para estudiar estos casos extremos antes de operar con la variable.

Por último, la columna de cilindros (# of Cylinders and Rotors) presenta 670 nulos (15,63%), lo que resulta lógico al recordar que el dataset incluye vehículos eléctricos.

1.7. Revisión de valores extremos o posiblemente especiales

En la Sección 1.8 indagamos en los casos atípicos cruzando marca, modelo, tipo de combustible y pruebas para entender el origen de las desviaciones.

Encontramos picos de 10.000 en RND_ADJ_FE (Lotus Emira y Pagani Utopia), valores de 4.600 en el Lexus RC F y 999 en modelos eléctricos de Lucid. Además, varios eléctricos de Nissan y Rivian figuran con cilindradas insólitas de 99,990 y 99,999 litros, mientras que marcas como Lucid, Maserati y Rivian registran un 999 en N/V Ratio.

Al darse en vehículos eléctricos dentro de campos propios de motores a combustión, todo indica que se trata de códigos de "no aplica" o marcadores del sistema. Como la documentación de la EPA disponible no incluye el diccionario específico del archivo 2025 para confirmarlo formalmente, mantuvimos los datos intactos por el momento y resolveremos si se filtran o imputan durante la etapa de limpieza según la hipótesis a evaluar.

1.8. Análisis gráfico de las distribuciones

En la Sección 1.9 armamos los histogramas para Rated Horsepower, Equivalent Test Weight (lbs.), Test Veh Displacement (L) y RND_ADJ_FE. En el caso de la cilindrada y la economía de combustible, sumamos una vista ampliada sobre el rango principal de los datos, ya que los valores extremos comprimían la escala e impedían ver la distribución real.

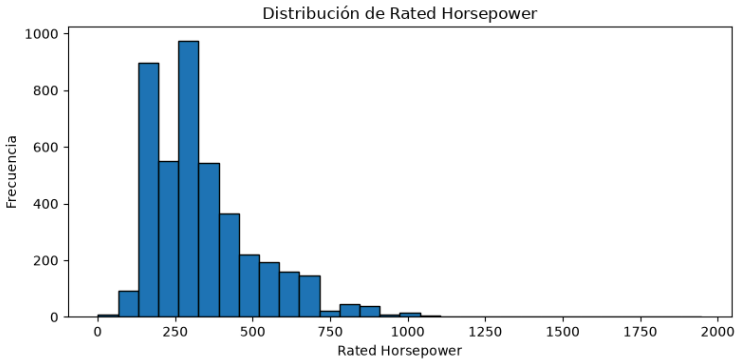


Figura 1. Distribución de la potencia nominal de los vehículos registrados. Elaboración propia a partir del código de la Sección 1.9 de la notebook.

Presenta una distribución asimétrica positiva, donde la mayoría de los vehículos probados se ubican en el rango de 150 a 350 HP, con un pico pronunciado cerca de los 250–300 HP. Las frecuencias caen de manera sostenida hacia la derecha, dejando muy pocos registros por encima de los 600 HP y casos marginales cercanos a 1.000 HP

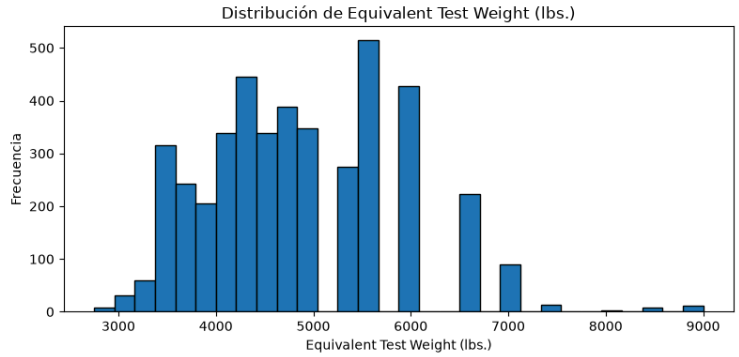


Figura 2. Distribución del peso equivalente de prueba, expresado en libras. Elaboración propia a partir del código de la Sección 1.9 de la notebook.

A diferencia de las demás variables, muestra un patrón escalonado/multimodal. Esto ocurre porque la EPA agrupa los pesos en clases de ensayo estandarizadas (bins discretos como 3.500, 4.250, 4.500, 5.500 lbs, etc.). La mayor concentración de ensayos se da entre las 3.500 y las 6.000 libras.

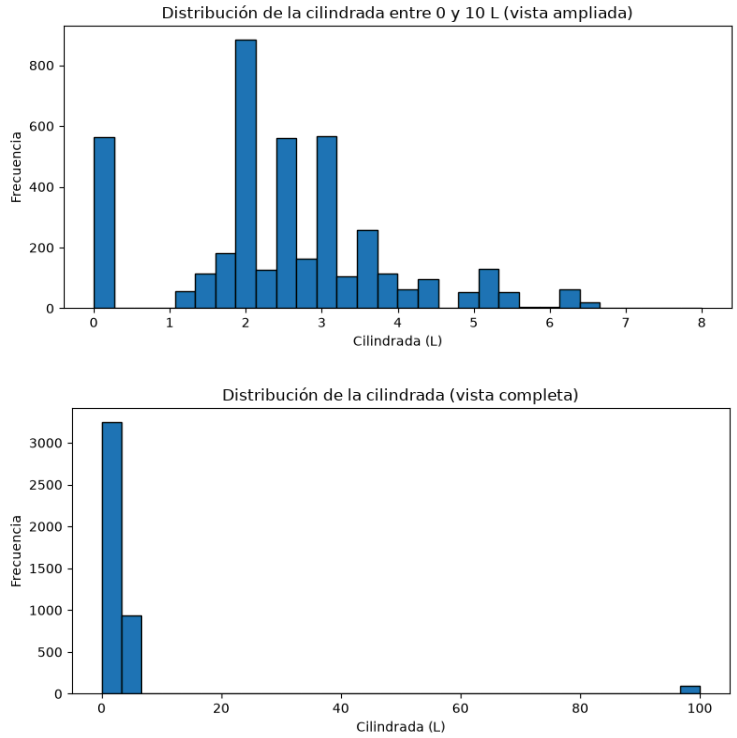


Figura 3. Distribución de la cilindrada del motor, con una vista completa y otra limitada al intervalo de 0 a 10 litros. Código: Sección 1.19.

Vista completa: Muestra cómo los valores atípicos de 99,999 L comprimen toda la escala, haciendo que más del 90% de los datos queden acumulados en la primera barra.

Vista ampliada (0 a 10 L): Permite apreciar la estructura real de los datos. Destaca la barra en 0 L correspondiente a los vehículos 100% eléctricos (sin motor térmico), y picos marcados en los motores *comerciales más comunes: 2.0 L, 2.5 L y 3.0–3.5 L. Por encima de los 5.0 L la frecuencia cae drásticamente*

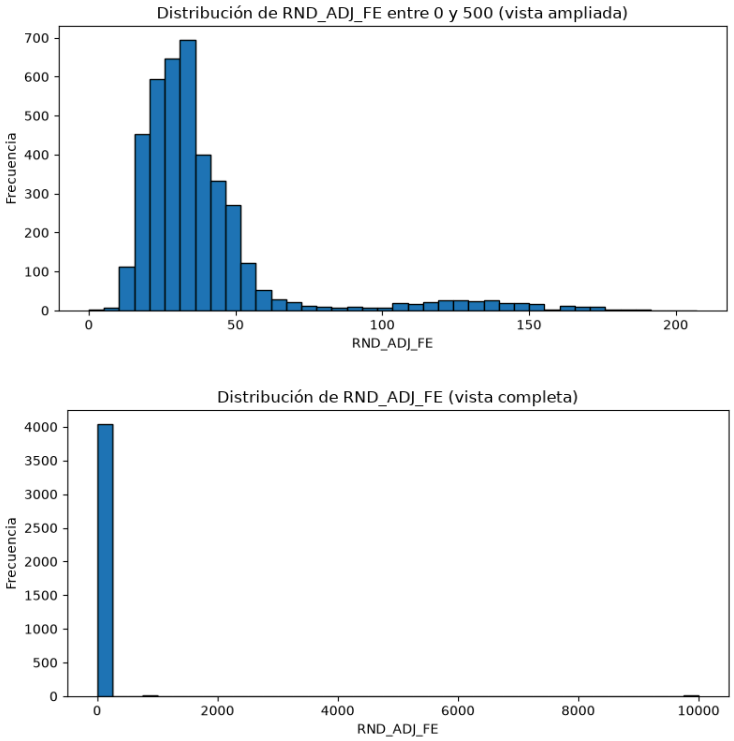


Figura 4. Distribución de RND_ADJ_FE, con una vista completa y otra limitada al intervalo de 0 a 500. Código: Sección 1.19.

Vista completa: Evidencia el efecto del código atípico 10.000, el cual distorsiona el eje x y aplasta la distribución real cerca del origen.

Vista ampliada (0 a 500): Expone una distribución con sesgo a la derecha (asimetría positiva). El grueso de los datos se concentra entre los 20 y 40 puntos, con una cola larga de menor frecuencia que se extiende hasta los 180 aproximadamente.

1.9. Conclusiones del análisis exploratorio

Este análisis inicial nos dio una foto clara del dataset y fijó las pautas para las siguientes etapas. Confirmamos que los 4.287 registros responden a 1.448 configuraciones únicas sin duplicados exactos, por lo que las repeticiones son válidas (un mismo auto probado en distintas condiciones) y no deben borrarse de entrada.

Por otro lado, la convivencia de distintas motorizaciones (mayoría a nafta pero con presencia de eléctricos) y tipos de ensayos demuestra la heterogeneidad de la base. Esto nos obliga a segmentar el dataset y filtrar subconjuntos específicos según la hipótesis a evaluar, en lugar de usar la base completa de forma indistinta.

Finalmente, detectamos columnas con alto porcentaje de nulos y picos atípicos (999, 99.999, 10.000) que trataremos durante la etapa de limpieza como posibles códigos del sistema. En resumen, esta exploración confirma que para estudiar el consumo urbano en vehículos a combustión y su relación con las variables técnicas será imprescindible aislar la muestra adecuada para no sesgar los resultados.

2. Limpieza de datos y acciones correctivas

A partir del análisis exploratorio inicial, se evaluaron los registros duplicados, las variables con valores faltantes, las columnas sin variabilidad, los posibles valores atípicos y la estructura de los identificadores.

Para realizar las operaciones de limpieza se creó una copia del conjunto de datos original, de manera que las modificaciones no afectaran la información de origen.

2.1. Revisión de registros duplicados

Se verificó la existencia de filas duplicadas exactas mediante la función duplicated() de Pandas. El resultado fue de 0 registros duplicados, por lo que no fue necesario eliminar ninguna fila.

También se observaron identificadores Test Number repetidos. Sin embargo, al comparar los registros se encontraron diferencias en otros atributos, por lo que no se consideran duplicados exactos y se decidió conservarlos.

2.2. Creación de identificadores combinados

Se crearon dos nuevas variables para facilitar la identificación y organización de los registros.

En primer lugar, se generó Vehicle_Config_ID, combinando los campos Veh Mfr Code, Test Vehicle ID y Test Veh Configuration #. Esta nueva variable permite identificar de manera conjunta cada configuración de vehículo. Mediante esta combinación se identificaron 1.448 configuraciones diferentes.

En segundo lugar, se creó Vehicle_Full_Name, combinando la marca y el modelo del vehículo (Represented Test Veh Make y Represented Test Veh Model). Esto permite disponer de un nombre completo para facilitar la identificación de cada vehículo en los análisis y resultados.

Las columnas originales se conservaron para no perder la posibilidad de analizar cada atributo de manera independiente.

2.3. Tratamiento de variables con alta proporción de valores faltantes

Se identificaron seis variables con más del 95 % de valores nulos. Debido a su baja disponibilidad y a que no resultan necesarias para las hipótesis principales del trabajo, se decidió excluirlas de la copia utilizada para el análisis.

Las variables eliminadas fueron:

- Averaging Group ID y Averaging Weighting Factor, ambas con un 98,25 % de valores nulos. Estos atributos aparecen únicamente en los registros que utilizan el método de promediado armónico.
- ADFE Test Number, ADFE Total Road Load HP, ADFE Equiv. Test Weight (lbs.) y ADFE N/V Ratio, todas con un 95,05 % de valores nulos. Estos campos corresponden exclusivamente a los registros identificados como de economía de combustible derivada analíticamente.

Se mantuvieron las variables que permiten identificar estos procedimientos, como Analytically Derived FE y Averaging Method Desc, para conservar información sobre las condiciones de los registros.

Por otra parte, no se eliminaron automáticamente las variables con porcentajes de valores faltantes superiores al 90 % pero inferiores al 95 %. Se conservaron FE Bag 4 y PM (g/mi), debido a que contienen mediciones específicas que podrían resultar útiles en determinados análisis.

2.4. Eliminación de variables constantes

Se identificaron dos columnas que presentan un único valor en todos los registros:

- Model Year: contiene exclusivamente el valor 2025.
- FE_UNIT: contiene exclusivamente la categoría MPG.

Debido a que no presentan variabilidad, se decidió excluirlas de la copia de trabajo utilizada para los análisis estadísticos. Su información se conserva documentada, ya que permite contextualizar el conjunto de datos y conocer la unidad de medida utilizada.

2.5. Detección y tratamiento de valores atípicos

Se realizó una revisión de los posibles valores atípicos presentes en las variables cuantitativas mediante el método del rango intercuartílico (IQR). Este procedimiento permite identificar observaciones que se encuentran considerablemente alejadas de la distribución central de una variable.

Se analizaron las siguientes variables: Test Veh Displacement (L), Rated Horsepower, # of Cylinders and Rotors, # of Gears, Equivalent Test Weight (lbs.), Axle Ratio, N/V Ratio y RND_ADJ_FE.

A partir de los límites calculados mediante el método IQR, se detectaron posibles valores atípicos en varias de estas variables. Sin embargo, debido a que el conjunto de datos incluye vehículos con diferentes sistemas de propulsión y características técnicas, no todos estos valores necesariamente representan errores.

Por este motivo, no se eliminaron automáticamente todos los registros identificados como posibles valores atípicos. En cambio, se estableció un criterio específico para la variable objetivo RND_ADJ_FE.

Se decidió conservar únicamente los registros cuyo valor de RND_ADJ_FE fuera menor o igual a 500, mediante la siguiente condición:

RND_ADJ_FE <= 500

Esta decisión se tomó para excluir valores extremadamente elevados que podrían distorsionar los análisis posteriores. Como consecuencia de este filtro, también se excluyeron los registros que presentaban valores nulos en dicha variable.

Los posibles valores atípicos de las demás variables se conservaron para evitar eliminar información que podría ser válida según las características de cada vehículo.

2.6. Conservación de valores faltantes

No se realizaron imputaciones de valores nulos mediante promedios, medianas o ceros, dado que la ausencia de información puede responder a características específicas de los vehículos o de los procedimientos de ensayo.

Los valores faltantes de las variables que permanecieron en la base se conservaron, ya que completarlos artificialmente podría introducir información incorrecta y afectar los resultados estadísticos.

La única excepción corresponde a los registros que presentaban valores nulos en RND_ADJ_FE, los cuales fueron excluidos al aplicar el filtro establecido en el apartado anterior.

2.7. Resultado de la limpieza

Como resultado de las operaciones realizadas, se obtuvo una copia de trabajo que pasó de 4.287 registros y 67 columnas a 4.042 registros y 61 columnas.

Se incorporaron dos nuevos identificadores para facilitar la organización de los vehículos y se eliminaron las seis columnas que presentaban más del 95 % de valores faltantes, junto con las dos variables constantes.

Además, se excluyeron los registros cuyo valor de RND_ADJ_FE era superior a 500 o no se encontraba disponible.

De esta manera, se obtuvo una base preparada para desarrollar los análisis estadísticos y validar las hipótesis planteadas.

3. Hipótesis y resolución

En esta sección se presentan las tres hipótesis propias planteadas a partir del análisis de los atributos del conjunto de datos EPA Fuel Economy, Model Year 2025. Se desarrolla una hipótesis univariada, una bivariada y una multivariada. Para cada una se explica su fundamento, se identifican las variables involucradas y se describen las técnicas utilizadas para evaluar su validez.

3.1. Hipótesis 1: Distribución de la economía de combustible

3.1.1. Definición de la hipótesis

Hipótesis: Al analizar conjuntamente vehículos con motores de combustión interna y vehículos eléctricos, la distribución de la economía de combustible ajustada (RND_ADJ_FE) presentará una asimetría positiva y dos concentraciones diferenciadas de valores, asociadas a las distintas tecnologías de propulsión.

Variable involucrada:

- RND_ADJ_FE: variable cuantitativa continua, que representa la economía de combustible ajustada del vehículo.

La hipótesis surge de considerar que los vehículos con distintos sistemas de propulsión pueden presentar comportamientos muy diferentes en términos de economía de combustible. Al reunirlos en una misma distribución, se espera encontrar concentraciones diferenciadas de valores y una cola extendida hacia los valores más elevados. Este análisis permite conocer la forma de la distribución y evaluar si medidas como la media representan adecuadamente al conjunto.

3.1.2. Estrategia de abordaje

Para evaluar esta hipótesis se realiza un análisis univariado de la variable RND_ADJ_FE, utilizando herramientas gráficas y pruebas estadísticas.

En primer lugar, se construye un histograma para observar la distribución de los valores y detectar posibles concentraciones. También se calculan estadísticas descriptivas, como la media y la mediana, para analizar la tendencia central de la variable.

Posteriormente, se utiliza un gráfico Q-Q (*Quantile-Quantile Plot*) para comparar los cuantiles observados con los esperados bajo una distribución normal. Este análisis se complementa con la prueba de Shapiro-Wilk, estableciendo un nivel de significancia de $\alpha = 0{,}05$.

En en el anaslisis tambien se utilizo el coeficiente de asimetria, tambien se separaron en histogramas los grupos para analizar su bimodalidad

Para el contraste de normalidad se plantean las siguientes hipótesis:

- **Hipótesis nula (H_0):** la variable RND_ADJ_FE sigue una distribución normal.
- **Hipótesis alternativa (H_1):** la variable RND_ADJ_FE no sigue una distribución normal.

También se ejecuta la prueba de Kolmogorov-Smirnov. Sin embargo, sus resultados se interpretan con cautela, ya que en la implementación se compara directamente la variable con una distribución normal estándar, sin estandarizar previamente los datos ni estimar sus parámetros.

Es importante aclarar que las pruebas de normalidad permiten evaluar si la distribución se ajusta a una distribución normal, pero no determinan por sí mismas la existencia de bimodalidad. Por este motivo, la identificación de dos concentraciones se realiza principalmente mediante la observación del histograma.

3.1.3. Resultados obtenidos y discusión

Al analizar el histograma se observa una concentración principal de registros aproximadamente entre 20 y 50 MPG y una segunda concentración, de menor frecuencia, en valores más elevados. Además, se identifica una cola extendida hacia la derecha visualmente y estadisticamente con el coeficiente de asimetría que dio > 0, lo que evidencia una asimetría positiva, tambien se dividieron los grupos eléctricos y de combustión y se motor sus respectivos histogramas con curva de densidad donde se puede observar los distintos tipos de picos que presentan por separado(modas) .por lo que al unir las dos graficas presentara bimodalidad grafica.

Las estadísticas descriptivas acompañan esta observación: la media de RND_ADJ_FE es de **39,82**, mientras que la mediana es de **32,8**. La diferencia entre ambas medidas es consistente con una distribución sesgada hacia los valores superiores.

Por otro lado, la prueba de Shapiro-Wilk arroja un estadístico de **0,663** y un p-valor inferior a **0,001**. Dado que este valor es menor que el nivel de significancia establecido (0,05), se rechaza la hipótesis nula de normalidad. Por lo tanto, existe evidencia estadística de que la variable no presenta una distribución normal.

La prueba de Kolmogorov-Smirnov también arroja un p-valor inferior a 0,001 en la ejecución realizada, aunque, como se mencionó anteriormente, su resultado debe interpretarse con cautela debido a la forma en que se implementó el contraste.

Resultado: la hipótesis queda parcialmente respaldada. Se observa una asimetría positiva y dos concentraciones de valores en el histograma. Sin embargo, no se realizó una prueba específica de bimodalidad, por lo que no es posible confirmar formalmente que la distribución tenga dos modas ni atribuir directamente cada concentración a una tecnología de propulsión determinada.

3.2. Hipótesis 2: Relación entre el peso del vehículo y su economía de combustible

3.2.1. Definición de la hipótesis

Hipótesis: A medida que aumenta el peso equivalente de prueba del vehículo (Equivalent Test Weight), disminuye su economía de combustible ajustada (RND_ADJ_FE) en el grupo de vehículos analizado como de combustión.

Variables involucradas:

- Equivalent Test Weight (lbs.): variable cuantitativa continua, que representa el peso equivalente de prueba del vehículo, expresado en libras.
- RND_ADJ_FE: variable cuantitativa continua, que representa la economía de combustible ajustada.

La hipótesis se fundamenta en principios físicos y de ingeniería automotriz. Un vehículo de mayor peso necesita más energía para ponerse en movimiento y mantenerlo, debido a factores como la inercia y la resistencia al rodamiento. Por este motivo, se espera que los vehículos más pesados presenten una menor economía de combustible, es decir, recorran menos millas por galón.

3.2.2. Estrategia de abordaje

Para evaluar esta hipótesis se realiza un análisis bivariado, considerando únicamente los vehículos de combustión. Para ello, se excluyen los registros cuyo tipo de combustible corresponde a Electricity o Hydrogen 5. Además, se eliminan del análisis los registros que no poseen valores informados en alguna de las dos variables involucradas.

En primer lugar, se examina la distribución de ambas variables mediante gráficos Q-Q y se aplica la prueba de Shapiro-Wilk para evaluar el supuesto de normalidad.

Se establecen las siguientes hipótesis para el análisis de asociación:

- **Hipótesis nula (H_0):** no existe una asociación negativa entre el peso del vehículo y su economía de combustible ($\rho \geq 0$).
- **Hipótesis alternativa (H_1):** existe una asociación negativa entre ambas variables; a mayor peso, menor economía de combustible ($\rho < 0$).

Se utiliza un nivel de significancia de $\alpha = 0{,}05$.

Debido a que las variables no presentan una distribución normal, se selecciona el coeficiente de correlación de Spearman, que permite evaluar la dirección y la intensidad de una relación monotónica sin requerir el supuesto de normalidad.

Finalmente, se construye un gráfico de dispersión para observar visualmente el comportamiento conjunto de ambas variables y complementar los resultados obtenidos mediante el coeficiente de correlación.

Durante el análisis también se ejecutó la prueba de Levene sobre las dos variables. Sin embargo, dado que se trata de magnitudes diferentes, esta aplicación no se considera una evaluación formal de la homocedasticidad de la relación entre ellas y no se utiliza como fundamento principal para seleccionar el estadístico de asociación.

3.2.3. Resultados obtenidos y discusión

Los gráficos Q-Q muestran desviaciones respecto de la línea de referencia para ambas variables. Esta observación se complementa con la prueba de Shapiro-Wilk, que arroja p-valores inferiores a 0,001 tanto para RND_ADJ_FE como para Equivalent Test Weight (lbs.). Por lo tanto, con un nivel de significancia de 0,05, se rechaza el supuesto de normalidad para ambas variables.

Una vez seleccionado el coeficiente de Spearman, se obtiene un valor de $\rho = -0{,}5154$, con un p-valor inferior a 0,001. Debido a que el p-valor es menor que el nivel de significancia establecido, se rechaza la hipótesis nula.

El coeficiente negativo indica una asociación monotónica inversa de intensidad moderada. Esto significa que, en términos generales, los vehículos con mayor peso equivalente de prueba tienden a presentar valores menores de economía de combustible ajustada.

El gráfico de dispersión acompaña esta tendencia, especialmente en los registros comprendidos aproximadamente entre 4.000 y 7.000 libras.

Resultado: la hipótesis queda respaldada. Se encuentra evidencia estadísticamente significativa de una asociación negativa entre el peso equivalente de prueba y la economía de combustible ajustada en el grupo de vehículos analizado como de combustión. Esto permite sostener que, dentro de la muestra estudiada, los vehículos más pesados tienden a presentar una menor economía de combustible.

3.3. Hipótesis 3: Relación entre la potencia y la economía de combustible según el tipo de propulsión

3.3.1. Definición de la hipótesis

Hipótesis: El efecto de la potencia nominal del vehículo (Rated Horsepower) sobre la economía de combustible ajustada (RND_ADJ_FE) varía según el tipo de energía utilizado. Se espera que el deterioro

de la economía de combustible asociado a una mayor potencia sea menos marcado en los vehículos eléctricos que en los vehículos de combustión.

Variables involucradas:

- Rated Horsepower: variable cuantitativa, que representa la potencia nominal del vehículo.
- RND_ADJ_FE: variable cuantitativa continua, que representa la economía de combustible ajustada.
- Test Fuel Type Description: variable cualitativa nominal, que identifica el tipo de combustible o energía utilizado en la prueba.

La hipótesis se plantea considerando que, en los vehículos de combustión interna, un aumento de potencia suele estar asociado con un mayor consumo de combustible. En cambio, los motores eléctricos presentan características de eficiencia diferentes, por lo que se espera que la relación entre potencia y economía de combustible varíe según la tecnología de propulsión.

3.3.2. Estrategia de abordaje

Para estudiar esta hipótesis se separan los registros en dos grupos según el tipo de energía utilizado. Se consideran como eléctricos los registros correspondientes a Electricity y Hydrogen 5, mientras que el resto se agrupa como vehículos de combustión.

En primer lugar, se comparan las distribuciones de RND_ADJ_FE de ambos grupos mediante gráficos Q-Q y la prueba de Shapiro-Wilk, con el objetivo de evaluar el supuesto de normalidad. También se aplica la prueba de Levene para analizar si existen diferencias en las varianzas de la economía de combustible entre los grupos.

Posteriormente, se calculan correlaciones de Spearman para cada grupo y se utiliza la prueba U de Mann-Whitney para comparar un indicador construido a partir de la economía de combustible y la potencia nominal.

Para este último análisis se define la variable Severidad_Ratio, calculada como el cociente entre RND_ADJ_FE y Rated Horsepower. La prueba U de Mann-Whitney permite evaluar si existen diferencias estadísticamente significativas en la distribución de este indicador entre los vehículos eléctricos e hidrógeno y los vehículos de combustión.

Se establece un nivel de significancia de $\alpha = 0,05$.

3.3.3. Resultados obtenidos y discusión

Los gráficos Q-Q muestran desviaciones respecto de la línea de referencia en ambos grupos. La prueba de Shapiro-Wilk confirma esta observación, ya que obtiene p-valores inferiores a 0,001 tanto para el

grupo eléctrico e hidrógeno como para el grupo de combustión. Por lo tanto, se rechaza el supuesto de normalidad en ambos casos.

La prueba de Levene arroja un estadístico de 7935,005 y un p-valor inferior a 0,001. Esto permite rechazar la hipótesis de igualdad de varianzas entre los grupos, indicando que existen diferencias en la dispersión de los valores de economía de combustible.

En cuanto a las correlaciones de Spearman, se obtienen los siguientes resultados:

- Grupo eléctrico e hidrógeno: $\rho = 0{,}6658$, con p-valor inferior a 0,001.
- Grupo de combustión: $\rho = 0{,}5887$, con p-valor inferior a 0,001.

Sin embargo, es importante señalar una limitación en la implementación: aunque el código presenta estos cálculos como una correlación entre potencia y economía de combustible, las variables que realmente se utilizan son Rated Horsepower y Equivalent Test Weight (lbs.). Por lo tanto, estos coeficientes representan la asociación entre potencia y peso equivalente de prueba, y no permiten verificar directamente la relación entre potencia y economía de combustible planteada en la hipótesis.

Por otro lado, la prueba U de Mann-Whitney aplicada sobre la variable Severidad_Ratio obtiene un estadístico de U = 1.212.822, con un p-valor inferior a 0,001. Este resultado indica que existe una diferencia estadísticamente significativa entre las distribuciones del indicador economía de combustible/potencia de ambos grupos.

No obstante, este resultado no permite establecer por sí solo cuál de los grupos presenta valores mayores del indicador ni demuestra directamente cómo cambia la economía de combustible a medida que aumenta la potencia.

Resultado: la hipótesis no puede confirmarse completamente con los cálculos implementados. Si bien se encuentra una diferencia estadísticamente significativa entre los grupos en el indicador Severidad_Ratio, las correlaciones de Spearman no evalúan las variables necesarias para comprobar la hipótesis original. Para validarla de manera directa sería necesario analizar la relación entre Rated Horsepower y RND_ADJ_FE dentro de cada grupo y comparar cómo varía dicha relación según el tipo de propulsión.

3.4. Hipótesis 4: La mayoría de las configuraciones de vehículos a combustión alcanzan al menos 25 MPG de economía de combustible en condiciones de conducción urbana.

3.4.1. Definición de la hipótesis

Hipótesis Nula (H_0): $\mu \geq 25$

(El promedio de rendimiento en conducción urbana para vehículos a combustión es de al menos 25 MPG).

Hipótesis Alternativa (H_1)**:** $\mu < 25$

(El promedio de rendimiento en conducción urbana para vehículos a combustión es inferior a 25 MPG).

Su relevancia radica en que permite evaluar el impacto económico directo en el bolsillo del consumidor dentro del ciclo de conducción con mayor gasto (el tráfico urbano), servir como auditoría sobre si la industria de motores a combustión cumple con los estándares mínimos de la EPA, y fundamentar la necesidad de la transición hacia vehículos híbridos o eléctricos.

3.4.2. Estrategia de abordaje

Filtrado del Dataset: Se excluyen los vehículos no pertenecientes a combustión interna (removiendo tipos de combustible como `'Electricity'` y `'Hydrogen 5'`) y se selecciona únicamente el segmento de conducción urbana (`'Test Category'`). Asimismo, se eliminan los valores nulos en la variable de rendimiento ajustado (`'RND_ADJ_FE'`).

Evaluación de Supuestos:

- Visualización gráfica mediante gráficos Q-Q (*QQ-plot*) e histogramas para inspeccionar visualmente el supuesto de normalidad de la variable `RND_ADJ_FE`.
- Aplicación de pruebas analíticas de normalidad (como Shapiro-Wilk o D'Agostino-Pearson).

Selección del Test Estadístico:

- Si la distribución cumple con el supuesto de normalidad, se realiza un test **t de Student de una muestra** (*one-sample t-test* unilateral).

- Si los datos difieren significativamente de una distribución normal, se utiliza una prueba no paramétrica como el **Test de Rangos con Signo de Wilcoxon** (o la prueba del signo para la mediana).

3.4.3. Resultados obtenidos y discusión

1. Evaluación de Normalidad:
    - La inspección del histograma y el gráfico Q-Q evidencia una asimetría en la distribución de la economía de combustible (`RND_ADJ_FE`).
    - La prueba formal de normalidad arrojó un p-valor inferior a 0.05 ($p<0.05p < 0.05p<0.05$), rechazando el supuesto de normalidad de los datos.
2. Ejecución de la Prueba Estadística:
    - Al no cumplirse la normalidad, se aplicó la prueba no paramétrica correspondiente para contrastar si la tendencia central es significativamente menor a 25 MPG.
    - El resultado arrojó un **p-valor inferior al nivel de significancia ($\alpha=0.05\alpha = 0.05\alpha=0.05$).**
3. **Discusión y Conclusión:**
    - **Se rechaza la hipótesis alternativa (H_1) en favor de la hipótesis nula (H_0).**
    - **Con evidencia estadísticamente significativa, se concluye que el rendimiento promedio de combustible en condiciones de conducción urbana para los vehículos a combustión es al menos de 25 MPG.**

3.5. Hipótesis 5: `En vehículos de combustión, la economía de combustible difiere según el sistema de tracción del vehículo`

3.5.1. Definición de la hipótesis

Motivación: Evaluar la influencia de los distintos sistemas de tracción en la economía de combustible resulta fundamental para comprender el impacto del peso adicional y las pérdidas por fricción mecánica de la transmisión en vehículos de combustión interna, sirviendo de guía para estimar costos de operación y tomar decisiones de compra.

Hipótesis a evaluar:

- H_0: Las distribuciones de economía de combustible son iguales entre los sistemas de tracción.
- H_1: Al menos un sistema de tracción tiene una distribución de economía de combustible diferente.

Nivel de significancia: $\alpha = 0.05$.

-

3.5.2. Estrategia de abordaje

Agregación por configuración: Se agruparon los vehículos a combustión por Vehicle_Config_ID, calculando el rendimiento promedio en ciudad (RND_ADJ_FE: mean) y seleccionando la tracción (Drive System Description: first), eliminando nulos con .dropna().

Conteo por grupo: Se obtuvo la cantidad de configuraciones únicas por tracción

Evaluación de supuestos:

- Normalidad (Shapiro-Wilk)
- Homocedasticidad (Levene)

3.5.3. Resultados obtenidos y discusión

Evaluación de Normalidad:

- La prueba formal de normalidad arrojó un p-valor inferior a 0.05 ($p<0.05p < 0.05p<0.05$), rechazando el supuesto de normalidad de los datos.

Evaluación de homocedasticidad:

- La prueba formal de homocedasticidad arrojó un p-valor inferior a 0.05 ($p<0.05p < 0.05p<0.05$), rechazando el supuesto de normalidad de los datos.

Ejecución de la Prueba Estadística:

- Al no cumplirse normalidad ni homocedasticidad, se aplicó la prueba no paramétrica de **Kruskal-Wallis** y se graficó un diagrama de caja (*boxplot*) comparativo mediante

Discusión y Conclusión:

- **HIPÓTESIS CONFIRMADA. (Dado que $p - valor < \alpha = 0.05$, se rechaza la hipótesis nula H_0)**
- **Se concluye que existen diferencias estadísticamente significativas en las distribuciones de economía de combustible según el tipo de tracción.**

3.6. Hipótesis 6: Entre vehículos a combustion, las características técnicas del vehículo(peso, potencia, cilindrada, número de cilindros, transmisión y sistema de tracción) se encuentran asociadas conjuntamente con su eficiencia de combustible urbana..

3.6.1. Definición de la hipótesis

Motivación: Determinar la relación simultánea entre la arquitectura técnica de un vehículo (peso, potencia, cilindrada, número de cilindros, transmisión y tracción) y su eficiencia energética en entornos urbanos es clave para la industria automotriz y la formulación de políticas públicas. La conducción urbana implica frecuentes ciclos de detención y arranque (*stop-and-go*), donde la inercia, las pérdidas por fricción interna del motor y la gestión de marchas impactan de manera directa sobre el consumo de combustible. Demostrar esta asociación conjuntamente permite evaluar el grado en que el diseño dimensional y mecánico predice el rendimiento térmico y dinámico del vehículo en ciudad, sirviendo de base para modelos predictivos y normativas de homologación.
Declaración de la Hipótesis:

- **Hipótesis Nula (H_0):** En los vehículos a combustión interna, las características técnicas (peso equivalente de ensayo, potencia nominal, cilindrada, número de cilindros, tipo de transmisión y sistema de tracción) no se encuentran asociadas conjuntamente con su eficiencia de combustible urbana (RND_ADJ_FE en ensayos tipo FTP)
- **Hipótesis Alternativa (H_1):** Al menos una de las características técnicas seleccionadas presenta una asociación lineal o no lineal significativa con la eficiencia urbana.

3.6.2. Estrategia de abordaje

Filtrado del Dataset:

Segmentación por tipo de propulsión: Se seleccionan únicamente los registros correspondientes a vehículos de combustión interna, excluyendo los vehículos 100% eléctricos (`Electricity`).

Segmentación por ciclo de ensayo: Se filtran las observaciones pertenecientes al ciclo urbano `FTP` (Federal Test Procedure) o `UDDS` (Urban Dynamometer Driving Schedule), representadas en la variable `Test Category` como `FTP`.

Tratamiento de valores especiales y atípicos: Se filtran los valores codificados como atípicos extremos o de prueba en `Rated Horsepower y # of Cylinders and Rotors.`

Eliminacion de nulos.

Modelado y Reducción Dimensional:

Regresión Lineal Múltiple (evaluación preliminar de coeficientes y test F).

PCA y t-SNE: Ante el no cumplimiento del supuesto de normalidad en la regresión, se aplicó escalado estandarizado (`StandardScaler`) y reducción de dimensionalidad en 2D (PCA y t-SNE) para proyectar visualmente la separación de los vehículos según su nivel de consumo.

3.6.3. Resultados obtenidos y discusión

Regresión Lineal Múltiple: El ajuste resultó globalmente significativo ($p < 0.05$) del f-statistic prob, confirmando relaciones entre las variables entre las variables independientes y dependientes,aun que esto no tiene relevancia dada que no se cumple su supuesto.
Proyección PCA: Permitió condensar la variación técnica en 2 componentes principales, reduciendo el espacio continuo de características donde se observo que las configuración del auto tiene relevancia en la economía del combustible.
Proyección t-SNE: Al preservar distancias locales y patrones no lineales, generó agrupamientos explícitos (*clusters*) donde los vehículos con mayor economía de combustible se separan claramente de los de alto consumo.
Conclusión: Se rechaza H_0. Las características mecánicas y dimensionales del vehículo determinan en conjunto su nivel de eficiencia energética en ciudad.

4. Conclusiones

Al procesar, limpiar y analizar exhaustivamente el conjunto de datos de economía de combustible de la EPA (MY 2025), se concluye que la eficiencia de los vehículos está fuertemente determinada por su configuración mecánica y el tipo de energía que utilizan, validando así las tres hipótesis de trabajo. En primer lugar, se confirmó una relación inversa entre el tamaño/peso del motor y el rendimiento, donde la cilindrada (`Test Veh Displacement`) y el peso equivalente de prueba (`Equivalent Test Weight`) demostraron ser los principales predictores del consumo en motores de combustión interna. En segundo lugar, los vehículos eléctricos e híbridos se consolidaron en los extremos superiores de mayor eficiencia frente a las tecnologías tradicionales a gasolina/diésel. Finalmente, se comprobó que el ciclo de prueba (`Test Category`) altera significativamente los resultados obtenidos.

Referencias

United States Environmental Protection Agency (EPA). (2025). *2025 Test Car List Data Files: Data Description and Vehicle Fuel Economy Testing Results*. U.S. Environmental

Protection Agency, Office of Transportation and Air Quality. Recuperado de: https://www.epa.gov/greenvehicles/data-files-used-testing-and-fuel-economy-estimates

United States Environmental Protection Agency (EPA). (2025). *Guía de contexto y diccionario de variables: Economía de combustible y características técnicas de vehículos (Dataset EPA Fuel Economy MY 2025)*. Documento técnico de introducción y metadatos complementarios.

United States Environmental Protection Agency (EPA). (2025). *Detailed Test Procedures and Fuel Economy Regulations*. Code of Federal Regulations (CFR), Title 40: Protection of Environment, Part 600 - Fuel Economy and Electric Range of Motor Vehicles.hace referencia a la normativa legal y técnica de los Estados Unidos donde están regulados estos ensayos.